

S-MLFQ: 위상적 필터링 기반 다중 큐 탐색 엔진 설계

- 지식 그래프 RAG 환경에서의 LLM 환각 억제를 중심으로 -

과목명	담당 교수	소속	학번	이름
자료구조개론	염익준	소프트웨어학과	2024315881	길태호

2026.05.30.

목 차

1. 연구 주제 및 필요성

1.1 연구 배경 : LLM의 환각 현상과 Graph RAG의 대두

1.2. 문제 정의

1.2.1. 기존 탐색 자료구조의 한계

1.2.2. OS 스케줄링 기법과 Graph DB의 유사성 고안

1.3. 연구 주제 및 목표

1.3.1. 연구 주제 : S-MLFQ(Semantic Multi-Level Feedback Queue) 제안

1.3.2. 연구 목표

1.4. 연구의 필요성 및 독창성

2. 관련 연구 및 조사 결과

3. 구현 내용

3.1. 투트랙 시스템 아키텍처 개요

3.2. [Track 1] Web 기반 실시간 탐색 서비스 구현 (HTTPS Site)

3.2.1. 데이터 가공 및 탐색 파이프라인 (Front/Back-end 연동)

3.2.2. XAI(설명 가능한 인공지능) 및 동적 시각화 처리

3.2.3. 서비스 구현 UI 및 데모 시나리오

3.3. [Track 2] S-MLFQ 성능 평가 시스템 구축 (알고리즘 및 실험 환경)

3.3.1. 3대 평가 지표 정의 (OS 스케줄링 지표와의 매핑)

3.3.2. 환경별 이론적 가설

3.3.3. 핵심 탐색 알고리즘 구현 (Baseline 및 S-MLFQ)

3.3.4. 벤치마크 데이터셋 동적 생성 로직 및 위상적 설계

3.3.5. 제안 모델(S-MLFQ)의 이론적 시간 및 공간 복잡도 분석

4. 실험 및 분석 결과

4.1. [평가 A] 통제된 정상 지식망에서의 알고리즘 기본 탐색 성능 분석

4.1.1. 탐색 효율성 분석

4.1.2. 의미론적 적합성

4.1.3. 다양성 및 창발성

4.2. [평가 B] 적대적 스트레스 환경에서의 필터 버블 방어 능력 검증

4.2.1. 탐색 효율성 분석: 위상적 필터링의 증명

4.2.2. 의미론적 적합성 분석: 노이즈 우회 능력

4.2.3. 다양성 및 창발성 분석: 통제된 도약

4.3. 실측 시스템 리소스 (시간/공간 복잡도) 정밀 분석

4.3.1. 시간 복잡도 및 스케줄링 오버헤드 분석

4.4. 실제 지식망 위에서의 탐색 궤적 정성 평가

4.4.1. 대조군의 한계: 다익스트라의 국소 최적화 및 랜덤 워크의 표류 현상

4.4.2. 제안 모델의 위상적 감지 및 통제된 회귀 메커니즘 입증

4.5. 실험 및 분석 결과 총평

5. 결론 및 향후 연구 방향

5.1. 연구 요약 및 학술적 의의

5.2. 실무적/산업적 기대 효과

5.3. 본 연구의 한계점

5.4. 향후 발전 방향

6. LLM 활용 기록

6.1. LLM 활용 파이프라인 개요

6.2. 프롬프트 엔지니어링 적용 사례

6.2.1. 사례 1: Track 1의 지식 그래프 강제 연결성 부여

6.2.2. 사례 2: 적대적 스트레스 환경(평가 B) 생성기 설계

6.2.3. 사례 3: 시각화 시뮬레이션에서의 데이터 환각 검증 및 극복

[초록]

최근 거대언어모델(LLM)의 환각(Hallucination) 현상을 극복하기 위해 지식 그래프(Knowledge Graph) 기반의 RAG(Retrieval-Augmented Generation) 기술이 필수적으로 대두되고 있다. 그러나 기존 지식 탐색에 활용되던 다익스트라(Dijkstra) 알고리즘은 진입 비용이 낮고 무의미한 지식이 밀집된 '거대 노이즈 허브'에 갇히는 필터 버블(Filter Bubble) 현상에 취약하며, 랜덤 워크(Random Walk) 알고리즘은 무작위 도약으로 인해 질문의 의도를 벗어나는 의미론적 표류(Semantic Drift)를 유발하여 오히려 환각을 가중시키는 한계가 존재한다.

본 연구는 이러한 구조적 한계를 해결하기 위해, 운영체제(OS)의 다중 큐 스케줄링(MLFQ) 이론을 그래프 탐색 자료구조에 최초로 융합한 'S-MLFQ (Semantic Multi-Level Feedback Queue)' 아키텍처를 제안한다. 제안 모델은 노드의 연결 차수(Degree)가 임계치를 초과할 경우 이를 즉각 노이즈로 판별하여 최하위 큐(Q2)로 격리하는 $O(1)$ 상수 시간의 위상적 필터링(Topological Filtering)을 수행하여 연산 병목을 제거한다. 또한, 에이징(Aging) 메커니즘을 통해 탐색이 정제될 경우 의도적으로 타 도메인으로 문맥을 전환함으로써, 안전한 탐색 궤적을 유지하면서도 혁신적인 지식을 융합하는 '통제된 창발성'을 보장한다.

파이썬 기반 동적 벤치마크 환경을 구축하여 평가한 결과, 30% 비율의 노이즈가 주입된 적대적 스트레스 환경에서 대조군이 탐색 효율성과 의미론적 적합성 방어에 실패한 반면, S-MLFQ는 $O(V)$ 의 안정적인 선형 공간 복잡도를 유지하며 노이즈를 완벽히 우회하여 가장 높은 효율성과 적합성을 기록하였다. 결론적으로 본 연구의 S-MLFQ는 단순한 검색을 넘어 LLM의 환각을 통제하고 신뢰성 있는 지식 탐색을 가능하게 하는 차세대 Graph RAG 엔진으로서의 실무적, 학술적 효용성을 입증하였다.

1. 연구 주제 및 필요성

1.1 연구 배경 : LLM의 환각 현상과 Graph RAG의 대두

최근 거대언어모델(LLM)이 다양한 도메인에서 눈부신 성과를 거두고 있으나, 학습되지 않은 정보를 사실처럼 지어내는 환각(Hallucination) 현상은 여전히 가장 치명적인 한계로 지적된다. 이를 해결하기 위해 외부의 신뢰할 수 있는 정보를 실시간으로 검색하여 컨텍스트에 주입하는 RAG(Retrieval-Augmented Generation) 기술이 필수적으로 자리 잡았다. 특히 최근에는 단순한 벡터 유사도를 넘어, 지식 간의 복잡한 인과관계와 맥락을 반영할 수 있는 지식 그래프(Knowledge Graph) 기반의 RAG 자료구조가 주목받고 있다.

1.2. 문제 정의

1.2.1. 기존 탐색 자료구조의 한계

지식 그래프 상에서 LLM에게 필요한 최적의 컨텍스트를 수집하기 위해 기존에는 주로 두 가지 탐색 자료구조가 전통적으로 활용되었으나, 실제계의 노이즈가 포함된 환경에서는 다음과 같은 뚜렷한 한계를 보였다.

1) 비용 기반 우선순위 큐 (Dijkstra Approach): 눈앞에 보이는 탐색 비용(Weight)이 가장 낮은 노드만을 쫓아가는 방식이다. 이 방식은 가중치가 낮지만 의미 없는 정보들이 밀집된 '거대 노이즈 허브(Noise Hub)'로 빠져 탐색 예산을 탕진하는 필터 버블(Filter Bubble) 현상에 취약하다.

2) 무작위 탐색 (Random Walk Approach): 구글의 PageRank와 같이 일정 확률로 도약(Teleport)하는 방식이다. 이는 다양한 노드를 훑을 수는 있으나, 목적성 없이 표류하다가 질문의 의도와 전혀 무관한 지식을 수집하는 의미론적 표류(Semantic Drift)를 유발하여 오히려 LLM의 환각을 가중시킨다.

1.2.2. OS 스케줄링 기법과 Graph DB의 유사성 고안

기존의 탐색 자료구조 중 다익스트라 접근법은 매번 가장 짧은 경로를 택하는 방식이므로, OS의 CPU 스케줄링 기법 중 SJF(Shortest Job First)과 알고리즘이 거의 일치한다. 또한, 랜덤 워크 접근법은 랜덤하게 경로를 결정하므로, OS의 CPU 스케줄링 기법 중 Lottery 스케줄링 기법과 알고리즘이 거의 일치한다. 이 점에서 착안하여, 기존의 OS 스케줄링 알고리즘을 Graph DB의 탐색 알고리즘에 적용하는 아이디어를 고안하였다. 명시적으로 OS의 스케줄링 알고리즘을 그래프 탐색에 적용한 연구는 기존에 존재하지 않는

것으로 보인다. 본 연구는 최신 RAG 최적화 모델(SOTA)과의 단순 성능 경쟁을 목적으로 하지 않는다. 그보다는 전통적인 OS 스케줄링 이론이 지식 탐색 공간에서 직면하는 구조적 모순을 확인하고 이를 다중 큐 아키텍처로 극복하는 기초 이론의 증명에 무게를 둔다. 따라서 복잡한 최신 모델 대신, OS 스케줄링의 기초 개념(SJF, Lottery)과 1:1로 명확히 대응되는 다익스트라와 랜덤 워크를 핵심 비교군으로 선정하여 그 구조적 차이를 엄밀하게 대조하고자 한다.

기존의 OS의 CPU 스케줄링에서, 각 알고리즘의 평가 기준이 되는 지표는 performance(완료 시간), responsiveness(응답성), fairness(공정성)이다. 이 지표들을 Graph DB의 탐색 알고리즘에 대응시키면 각각 efficiency(탐색 리소스 효율), relevance(의미론적 적합성), diversity(탐색 다양성/창발성)이라고 추론하였다.

기존의 OS의 CPU 스케줄링에서, FCFS는 Graph DB의 DFS와 매칭되며, RR은 BFS, Strict Priority는 A*에 매칭될 수 있다. 하지만, MLFQ(Multi-Level Feedback Queue)와 매칭되는 Graph DB 알고리즘에 대한 연구는 찾을 수 없었다. 또한, OS의 스케줄링 기법에서는 MLFQ(Multi-Level Feedback Queue)가 3가지 평가지표에서 우수한 결과가 나오기에 현대에서 가장 많이 사용된다. 따라서, MLFQ를 Graph DB에 적용했을 때, 기존 알고리즘들 대비 상대적으로 우수한 성능을 내는지를 이론과 실제 데이터 모두를 바탕으로 검증하고자 하였다.

1.3. 연구 주제 및 목표

1.3.1. 연구 주제 : S-MLFQ(Semantic Multi-Level Feedback Queue) 제안

본 연구는 위와 같은 기존 자료구조의 한계를 극복하기 위해, 운영체제(OS)의 프로세스 스케줄링 기법인 다중 큐(Multi-Level Feedback Queue) 이론을 지식 그래프 탐색 자료구조에 최초로 융합한 'S-MLFQ' 아키텍처를 제안한다. 이 아키텍처에서 제안하는 S-MLFQ는 LLM이 미리 구축해 둔 지식망 위에서, 의미론적 일반성(노드의 간선 수)과 의미론적 연관성(Edge Weight)이라는 위상 데이터를 활용한다. 즉, 의미론적 계산을 탐색 실시간(Runtime)에서 구조적(Topological) 필터링으로 치환하여 속도와 정확도를 동시에 잡은 아키텍처이다.

1.3.2. 연구 목표

1) OS의 CPU 스케줄링 기법들을 Graph DB에서의 탐색 기법에 대응시켜, MLFQ를 Graph DB에 적용한 S-MLFQ가 기존 그래프 탐색 알고리즘과 대비하여 우리가 설정한 3가지 성능지표에서 상대적으로 더 우수한 결과를 내는지 이론

적으로 탐구한다. 이후 이론이 맞는지를 실제 데이터를 기반으로 구현하여 검증한다.

2) S-MLFQ를 동적 웹 파이프라인으로 구현하여, 실제 사용자가 이 아키텍처를 동작시킬 수 있도록 한다.

1.4. 연구의 필요성 및 독창성

본 연구가 제안하는 S-MLFQ 자료구조는 다음과 같은 측면에서 기존 연구들과 차별화되는 독창성과 학술적 필요성을 갖는다.

1) 위상적 필터링(Topological Filtering)을 통한 연산 병목 해결: 기존 RAG 시스템은 노드의 유효성을 검증하기 위해 탐색 실시간(Runtime)에 무거운 코사인 유사도 연산을 반복하여 심각한 병목을 겪었다. 본 연구는 노드의 연결 차수(Degree)가 특정 임계치(Threshold)를 초과할 경우 이를 환각을 유발하는 노이즈 허브로 규정하고 즉시 최하위 큐(Q2)로 격리하는 O(1) 시간 복잡도의 구조적 필터링을 도입하여 탐색 속도와 적합성을 동시에 극대화했다.

2) 통제된 창발성(Controlled Serendipity)의 수학적 구현: 지식 탐색의 홉(Hop)이 길어지면 타겟 큐를 강등시켜 한 우물만 파는 것을 방지하고, 일정 주기(Tick)마다 에이징(Aging) 메커니즘을 발동시켜 유배된 큐의 지식들을 구출한다. 이는 LLM이 안전한 문맥(Context)을 유지하면서도, 혁신적인 통찰(Insight)을 이끌어낼 수 있는 이중 도메인 지식을 적정 비율로 융합해 내는 '통제된 창발성'을 보장한다.

2. 관련 연구 및 조사 결과

본 장에서는 제안하는 S-MLFQ 아키텍처의 이론적 근거가 되는 선행 연구들을 분석한다. 본 관련 연구 조사 및 아이디어 구체화 과정 전반에 걸쳐 LLM(Gemini)을 적극적으로 활용하였으며, 이론적 융합의 타당성을 검증하는 데 도움을 받았다. 구체적인 프롬프트 요청 내용과 적용 결과는 '6. LLM 활용 기록'에서 상세히 서술한다.

1) 지식 그래프 기반 RAG (GraphRAG) 메커니즘

최근 마이크로소프트에서 발표한 GraphRAG 연구는 단순 벡터 유사도(Vector Similarity) 검색의 한계를 지적하며, 지식 그래프를 활용한 구조적 탐색이 컨텍스트의 포괄성과 환각 억제에 얼마나 효과적인지 증명했다[1]. 본 연구는 이 논문의 문제의식을 계승하되, 탐색 알고리즘 자체의 효율성을 개선하는 방향으로 확장되었다.

2) 다익스트라(Dijkstra) 최단 경로 탐색과 Graph DB 라우팅 '다익스트라' 탐색은 현대 Graph DB(Neo4j 등)에서 두 엔티티 간의 관계를 추적할 때 사용하는 가장 기초적이고 표준적인 최단 경로 알고리즘이다[2],[3]. 이 방식은 노드 간의 의미론적 거리를 간선의 가중치로 삼아 가장 비용이 낮은 안전한 경로를 탐욕적으로 추적한다. 본 연구에서 제안하는 S-MLFQ는 다익스트라의 단일 우선순위 큐를 다중 레벨로 분리하고, 에이징(Aging)과 예산 통제(Quantum) 기법을 도입함으로써 다익스트라의 탐색 효율성은 그대로 취하면서도 타 도메인으로의 '통제된 창발성'을 이끌어낸다는 점에서 명확한 차별성을 갖는다.

3) 무작위 행보(Random Walk)와 페이지랭크(PageRank) 본 연구의 베이스라인 모델 중 하나인 '랜덤 워크' 스케줄링은 구글의 초기 검색 알고리즘인 PageRank에 기반한다[4]. 논문에서 제시된 댄핑 팩터(보통 0.85) 개념을 차용하여, 본 실험에서도 탐색 중 15%의 확률로 시작 노드로 텔레포트(Context Switch)하는 복권 스케줄링(Lottery Scheduling) 모델을 구현하여 비교군으로 삼았다.

4) 척도 없는 네트워크와 위상적 허브

제안 모델(S-MLFQ)에서 노이즈를 걸러내는 핵심 로직인

"차수(Degree) 기반 위상적 필터링"의 수학적 근거가 되는 개념이다[5]. 현실의 지식 네트워크는 멍법칙을 따르며, 극소수의 허브 노드가 수많은 간선을 독식한다. 본 연구는 이 이론을 역이용하여, 차수가 비정상적으로 높은 노드(임계치 $k > 5$ 가정)를 영양가 없는 '노이즈 허브'로 규정하고 Q2로 강등시키는 최적화 로직을 설계했다.

5) 다중 큐 스케줄링 (MLFQ)

작업의 성격(CPU-bound vs I/O-bound)에 따라 우선순위 큐를 동적으로 이동시키고 기아(Starvation) 현상을 막기 위해 에이징을 적용하는 OS 이론[6]을, 지식 그래프 탐색의 '노이즈 격리' 및 '창발적 도메인 구출'에 1:1로 매핑하여 적용했다.

3. 구현 내용

본 프로젝트의 핵심 목표는 LLM의 환각 현상을 억제하기 위해 제안된 S-MLFQ(Semantic Multi-Level Feedback Queue) 자료구조를 실제 코드로 구현하고, 그 효용성을 다각도로 검증하는 것이다.

거대 지식 그래프 환경에서의 탐색은 심각한 메모리 병목 현상을 유발할 수 있으므로, 본 연구의 가장 핵심이 되는 탐색 엔진은 하드웨어 제어와 연산 속도에 최적화된 C++ 기반으로 자체 설계 및 구현되었다. 더불어 이 핵심 엔진의 범용성과 학술적 우수성을 동시에 입증하기 위해, 시스템 전체를 '웹 기반 실시간 RAG 탐색 서비스(Track 1)'와 '통제된 환경에서의 알고리즘 성능 벤치마크(Track 2)'라는 투트랙(Two-Track) 아키텍처로 확장하여 구축하였다.

3.1. 투트랙 시스템 아키텍처 개요

본 연구가 제안하는 S-MLFQ 자료구조는 단일 스크립트 수준의 실험을 넘어, 실제 상용화 가능한 수준의 어플리케이션과 엄밀한 학술적 검증 파이프라인을 모두 충족하도록 설계되었다. 두 트랙은 서로 다른 목적을 가지지만, C++로 컴파일된 단일 핵심 엔진(smlfq_engine.exe)을 공통으로 호출하여 작동한다. 각 트랙의 아키텍처 개요와 설계 의도는 다음과 같다.

1) Track 1: 실서비스 구현을 위한 동적 웹 파이프라인

설계 의도는 사용자의 비정형 자연어 입력이 실제 S-MLFQ 자료구조를 거쳐 시각적 결과물로 도출되는 End-to-End 실시간 파이프라인을 검증하기 위함이다.

아키텍처 흐름은 아래와 같다.

① Front-End(dashboard.html): 사용자가 텍스트 형태의 문서를 입력하고, 최종 탐색된 지식 그래프 궤적을 실시간으로 확인하는 대시보드 인터페이스이다.

② LLM 기반 지식 추출 (extractor.py): Flask 기반의 백엔드 웹 서버(app.py)가 사용자 입력을 수신하면, Ollama API(Llama3.1 모델[7] 등)를 호출한다. 이때 정교한 프롬프트 엔지니어링을 통해 텍스트 내의 엔티티(Node)와 인과관계(Edge)를 추출하여 graph_data.json 형태의 지식망 데이터로 실시간 가공한다.

③ 엔진 격발 및 XAI 후처리 (explainer.py): 파이썬 백엔드가 C++ 탐색 엔진을 서브프로세스로 격발시키며, 탐색이 완료되면 엔진이 반환한 큐의 상태 변화 로그를 활용하여 "왜 이 정보가 선택 혹은 배제되었는지"를 설명 가능한 형태(XAI)로 번역하여 프론트엔드로 전달한다.

2) Track 2: S-MLFQ 알고리즘 성능의 다각적 벤치마크 (정량/정성 평가 분리)

알고리즘의 범용성과 극한 상황에서의 견고함을 모두 검증하기 위함이다. 정상 환경(객관적 데이터)과 적대적 스트레스 환경을 분리하고, 이를 다시 3대 지표 정량 평가, 실측 복잡도 분석, 궤적 시각화의 단계로 세분화하여 제안 모델의

우수성을 입증한다.

① [평가 A] 정상 환경 기반 3대 매트릭스 정량 벤치마크: 통제된 객관적 지식 그래프(노이즈 0%)를 바탕으로 대조군(다익스트라, 랜덤 워크)과 실험군(S-MLFQ)을 동일한 예산으로 가동한다. 탐색 효율성, 의미론적 적합성, 다양성(창발성) 스코어를 산출하여 알고리즘의 기본 탐색 능력을 수치화한다.

② [평가 B] 스트레스 상황 데이터 기반 3대 매트릭스 정량 벤치마크: 진입 비용은 낮으나 빠져나올 수 없는 '거대 노이즈 허브'를 30% 비율로 인위적으로 섞어 넣은 악의적인 데이터셋을 생성한다. 이 가혹한 환경에서 비용 최적화 알고리즘이 겪는 필터 버블(Filter Bubble) 현상을 유도하고, S-MLFQ가 이를 어떻게 극복하는지 정량적으로 증명한다.

③ [평가 B 데이터 기반] 실효 리소스 (Time/Space Complexity) 분석: 평가 B의 노이즈 환경 하에서 C++ 내부 타이머를 통해 각 알고리즘이 소모한 순수 실행 시간(ms)과 방문 노드 기반 메모리 점유율을 측정한다. 이를 통해 노이즈를 처내는 O(1) 위상적 필터링의 연산 최적화 효과를 교차 검증한다.

④ [평가 B 데이터 기반] 탐색 궤적(Trace) 정성적 시각화 증명: 평가 B와 동일한 맵 위에서 탐색 예산을 초반부(예: 15단계)로 제한하여 각 엔진이 남긴 실제 발자취를 NetworkX[8] 기반으로 시각화(real_data_case_study_layered.png)한다. 다익스트라가 노이즈 허브에 갇혀 표류하는 모습과 S-MLFQ가 타겟 도메인으로 도약하는 메커니즘을 직관적인 그림으로 입증한다.

3.2. [Track 1] Web 기반 실시간 탐색 서비스 구현 (HTTPS Site)

3.2.1. 데이터 가공 및 탐색 파이프라인 (Front/Back-end 연동)

사용자와 상호작용하는 웹 서버는 Flask 기반의 app.py로 구현되었으며, 데이터 가공부터 탐색까지의 파이프라인은 다음과 같이 설계되었다.

1) 지식 추출 (extractor.py): 사용자가 웹 프론트엔드(dashboard.html)에서 줄글 형태의 비정형 텍스트를 입력하면, 백엔드에서 로컬 LLM(Ollama API, Llama3.1 모델)을 호출한다. 정교한 프롬프트 엔지니어링을 통해 텍스트 내의 핵심 엔티티(Node)와 인과관계(Edge)를 추출하며, 고아 노드가 발생하지 않도록 강제 병합 알고리즘을 거쳐 graph_data.json 포맷으로 변환한다.

2) IPC 통신 및 엔진 격발: 가공된 JSON 데이터와 사용자의 탐색 요청(시작 노드, 예산)은 파이썬의 subprocess.run 모듈을 통해 컴파일된 C++ 탐색 엔진(cli_chatbot.exe)으로 전달된다. 엔진은 메모리 상에서 S-MLFQ 탐색을 완료한 후, 방문한 노드 배열과 큐의 상태 변화 로그를 result.json으로 반환하여 파이썬 백엔드로 넘겨준다.

3.2.2. XAI(설명 가능한 인공지능) 및 동적 시각화 처리

단순히 탐색된 텍스트 결과만 반환하는 기존 RAG의 블랙박스(Black-box) 한계를 극복하기 위해, 탐색 과정을 투명하게 공개하는 인터페이스를 구현했다.


1) XAI 로그 해석기 (explainer.py): C++ 엔진이 뱉어낸 큐의 강등 및 에이징 로그를 자연어로 해석하여, "해당 노드가 노이즈로 판별되어 배제되었는지" 혹은 "피로도 누적으로 인해 궤적을 수정했는지" 등 탐색의 논리적 인과관계를 사용자에게 설명한다.

2) 동적 웹 렌더링: 프론트엔드에서는 자바스크립트 네트웍 라이브러리를 활용하여, 추출된 지식망의 전체 위상과

S-MLFQ의 실시간 큐 이동 궤적을 브라우저 상에 동적인 그래프로 시각화하였다.

3.2.3. 서비스 구현 UI 및 데모 시나리오

본 연구에서 구축한 웹 기반 파이프라인(Track 1)은 사용자가 S-MLFQ의 탐색 과정을 직관적으로 이해할 수 있도록 3단계의 대시보드 인터페이스(Dashboard UI)로 구성되었다.



[그림 1] 구현된 서비스 페이지

전체적인 구동 시나리오는 다음과 같다.

1) [Step 1] 비정형 텍스트 지식 추출 (Input & Extraction)
사용자가 상단의 입력창에 비정형 텍스트를 입력하고 추출 버튼을 누르면, 백엔드의 LLM 프롬프트 엔지니어링 파이프라인이 가동되어 텍스트 내의 핵심 엔티티(Entity)와 인과관계를 동적으로 분석한다. [그림1]에서는 현대 프랑스 철학자 질 들뢰즈와 펠릭스 가타리가 그들의 저서 『천 개의 고원』에서 제시한 '리좀(Rhizome)'에 관한 글을 인용하여 입력하였다.

2) [Step 2] 동적 지식 그래프 렌더링 (Vis.js 기반)

LLM이 추출한 JSON 형태의 지식망 데이터는 좌측 하단의 캔버스에 Vis.js 라이브러리를 통해 즉각적인 물리 시뮬레이션 그래프로 렌더링된다. 사용자는 시각화된 노드들을 마우스로 드래그하며 형성된 맵의 위상(Topology)과 '사물들의 틈새', '만드시 연결되어야 함' 등의 관계성을 직접 확인할 수 있다.

3) [Step 3] S-MLFQ 엔진 탐색 및 다중 큐(Queue) 상태 모니터링

우측 하단의 탐색 패널에서 시작 노드(예: "리좀")와 탐색 예산(Budget: 20)을 설정한 후 엔진을 격발시킨다. C++ 코어 엔진이 연산을 수행하며, 각 탐색 스텝마다 내부 큐에 노드들이 적재되고 에이징되어 강등되는 스케줄링 과정을 거친다.

4) [Step 4] XAI 엔진 스케줄링 로그

탐색이 1초 이내에 완료되면, 최하단 패널에 C++ 엔진이 수집한 '핵심 문맥'의 최종 결과물과 함께 "어떤 순서로 노드가 수집 및 필터링되었는지"에 대한 엔진의 내부 결정 과정이 인간이 읽을 수 있는 XAI 로그 형태로 출력된다. 이를 통해 블랙박스였던 탐색 과정을 투명하게 시각화하여 시스템의 신뢰성을 확보하였다.

3.3. [Track 2] S-MLFQ 성능 평가 시스템 구축 (알고리즘 및 실험 환경)

3.3.1. 3대 평가 지표 정의 (OS 스케줄링 지표와의 매핑)

제한하는 알고리즘의 성능을 객관적으로 채점하기 위해, 전통적인 운영체제의 CPU 스케줄링 평가 지표를 지식 그래프 탐색 도메인에 맞게 재해석하여 3대 핵심 평가 지표를 도출하였다.

1) 탐색 효율성 (Efficiency)

OS에서의 CPU 이용률 및 처리량 (Throughput)의 지표로부터 도출하였다. OS에서 이 지표는, 주어진 시간 동안 CPU가 쉬지 않고 얼마나 많은 유효 프로세스를 처리했는가를 의미한다. 이 지표를 그래프 탐색에서 탐색 효율성으로 재해석하였다. 이는 그래프 탐색에서 한정된 탐색 예산(Budget) 내에서 영양가 없는 '노이즈 허브' 방문을 최소화하고 유효한 지식을 수집한 비율을 의미한다. 무한 루프나 I/O 대기기에 빠지지 않고 탐색 자원을 얼마나 알뜰하게 사용했는지를 측정한다.

2) 의미론적 적합성 (Relevance)

OS의 반환 시간 및 목적 달성도(Turnaround Time) 지표로부터 도출하였다. OS에서 이 지표는 특정 프로세스가 시스템에 진입하여 목적을 달성하고 종료될 때까지 걸린 시간과 정확도를 의미한다. 이 지표를 그래프 탐색에서 의미론적 적합성으로 재해석하였다. 이는 그래프 탐색에서 질문의 핵심 문맥인 황금 경로(Golden Path) 관련 지식들을 얼마나 깨닫지 못하여 안정적으로 수집했는지를 측정한다.

3) 다양성 및 창발성(Diversity)

OS의 기아(Starvation) 방지 및 공정성(Fairness) 지표로부터 도출하였다. OS에서 이 지표는 우선순위가 낮은 프로세스도 영원히 배제되지 않고 적절히 실행 기회를 얻는가를 의미한다. 이 지표를 그래프 탐색에서 다양성 및 창발성으로 재해석하였다. 이는 그래프 탐색에서 기본 문맥과 거리가 멀고 진입 가중치가 높지만, 혁신적인 영감을 줄 수 있는 이중도메인(Hidden Target)을 탐색한 비율이다. 특정 문맥(단일 큐)에만 갇히지 않고 지식의 스펙트럼을 넓히는 공정성을 의미한다.

3.3.2. 환경별 이론적 가설

앞서 3.1절에서 설계한 Track 2의 다각적 벤치마크 파이프라인에 따라, 대조군(다익스트라, 랜덤 워크)과 실험군(S-MLFQ)이 각 평가 단계에서 보일 결과에 대한 이론적 가설을 다음과 같이 수립하였다.

1) [평가 A] 정상 환경(노이즈 0%) 3대 지표 가설

① 탐색 효율성:

다익스트라는 비용 최적화(SJF) 특성상 진입 비용이싼 유효 노드들을 무난하게 수집하며 준수한 효율성을 보일 것이다. 랜덤 워크는 무작위 탐색 특성상 의미 없는 노드를 이탈 및 방문하며 예산을 낭비하여 효율성이 가장 낮을 것이다. 제안 모델인 S-MLFQ는 최상위 큐(Q0)를 통해 핵심 문맥만을 정밀하게 타겟팅하므로 가장 우수한 탐색 효율성을 기록할 것이다.

② 의미론적 적합성:

다익스트라는 시작 노드 주변에 밀집된 황금 경로 지식들을 안정적으로 수집하여 높은 적합성을 기록할 것이다. 랜덤 워크는 15% 확률의 도약(Teleport) 메커니즘으로 인해 황금 경로를 스스로 이탈하는 '의미론적 표류'를 겪어 적합성이 크게 훼손될 것이다. S-MLFQ는 Q0에서 황금 경로를 띠므로 다익스트라와 동등하거나 비등한 최상위권 적합성 점수를 얻을 것이다.

③ 다양성 및 창발성:

다익스트라는 진입 비용이 매우 높게 설정된 창발성 도메인에는 구조적으로 절대 도달할 수 없어 다양성 점수는 0점에 수렴할 것이다. 랜덤 워크는 무작위 도약을 통해 우연히 도달할 수 있으나, 단순 요행이므로 점수 편차가 매우 클 것이다. S-MLFQ는 에이징 메커니즘을 통해 의도적이고 주기적인 문맥 전환을 수행하여 창발성 도메인에 안착, 가장 안정적인 다양성 점수를 확보할 것이다.

2) [평가 B] 스트레스 환경(노이즈 30%) 3대 지표 가설
진입 가중치는 매우 낮지만 무의미한 지식이 방사형으로 얹혀 있는 '함정'이 대거 배치된 적대적 환경에서의 가설이다.

① 탐색 효율성:

다익스트라는 진입 비용이싼 노이즈 허브의 미끼에 완벽하게 유인되어 효율성이 바닥으로 추락하는 치명적인 '필터 버블' 현상에 갇힐 것이다. 랜덤 워크는 노이즈 허브에 빠지더라도 15% 텔레포트 덕분에 역지로 탈출할 수 있어, 역설적으로 다익스트라보다 높은 효율성을 방어할 것이다. S-MLFQ는 연결 차수(Degree > 5)를 검사하는 위상적 필터링으로 거대 허브를 즉각 규명하고 최하위 큐(Q2)로 격리하므로, 스트레스 상황에서도 흔들림 없이 고효율을 유지할 것이다.

② 의미론적 적합성:

다익스트라는 필터 버블에 갇혀 황금 경로를 완전히 이탈하므로 적합성 점수가 수직 하락할 것이다. 랜덤 워크는 노이즈의 방해와 텔레포트가 겹쳐져 궤적이 얽히는 최악의 의미론적 표류를 겪을 것이다. S-MLFQ는 노이즈를 성공적으로 우회하고 황금 경로만을 골라내어 적대적 환경에서도 압도적인 적합성 스코어를 방어할 것이다.

③ 다양성 및 창발성:

다익스트라는 노이즈 허브에서 예산을 모두 탕진하여 창발성 도메인 근처에도 가지 못할 것이다. 랜덤 워크는 맹목적인 탐색 특성상 거대 노이즈 환경에서는 창발성 타겟에 도달할 확률이 낮을 것이다. S-MLFQ는 노이즈 허브를 무시한 채 에이징을 발동시켜, 노이즈 받음 건너뛰고 창발성 타겟으로 정확히 징검다리 도약을 해낼 유일한 알고리즘이 될 것이다.

3) [복잡도] 스트레스 환경 실측 리소스(Time/Space) 가설
극단적인 노이즈 환경에서 C++ 엔진이 소모하는 시스템 리소스에 대한 가설이다.

① 시간 복잡도 (Execution Time): 다익스트라는 노이즈 허브 내부에서 무의미한 우선순위 큐 삽입/삭제 연산을 반복하다 조기 종료되어 실행 시간이 짧게 측정되거나 심각한 지연을 겪을 것이다. 반면 S-MLFQ는 3개의 다중 큐를 스케줄링하는 오버헤드가 발생함에도 불구하고, 노드를 O(1) 상수 시간으로 가지치기하여 유효한 탐색에만 연산 시간을 사용할 것이다.

② 공간 복잡도 (Memory Space): 한정된 탐색 예산 내에서 작동하므로, 세 알고리즘 모두 전체 노드 수(V)에 비례하는 O(V)의 선형 공간 복잡도를 초과하지 않으며, 메모리 누수나 기하급수적인 큐 적재 현상은 발생하지 않을 것이다.

4) [시각화] 스트레스 환경 탐색 궤적 가설

노이즈 환경에서 각 알고리즘이 남기는 실제 발자취(방문 노드 순서)에 대한 위상적 형태 가설이다.

① 다익스트라의 궤적: 시작점 근처의 거대 노이즈 허브(회색 군집) 내부로 궤적이 쏠리며, 한곳에 얽혀서 맴도는 형태가 시각적으로 관찰될 것이다.

② 랜덤 워크의 궤적: 뚜렷한 방향성 없이 그래프 전역을 산발적으로 가로지르는 난잡한 형태를 보일 것이다.

③ S-MLFQ의 궤적: 노이즈 허브(회색 군집)를 완벽하게 우회하여, 기본 지식(황금 경로) 군집에서 창발성 타겟(붉은 색 군집)으로 곧게 뻗어나가는 뚜렷하고 목적 지향적인 선형 궤적이 도출될 것이다.

3.3.3. 핵심 탐색 알고리즘 구현 (Baseline 및 S-MLFQ)

모든 알고리즘은 C++ 코어인 smlfq_engine.hpp 내에 구현되었다. 첫 번째 대조군인 다익스트라는 누적 가중치가 낮은 경로를 우선 탐색하는 priority_queue 기반의 SJF 스케줄링으로 구현되었으며, 두 번째 대조군인 랜덤 워크는 <random> 라이브러리의 메르센 트위스터 난수를 활용하여 1

5% 확률로 시작 노드로 회귀(Damping Factor)하는 복귀 스케줄링으로 구현되었다.

가장 핵심이 되는 실험군 S-MLFQ 알고리즘은 의미론적 유사도 계산의 $O(N)$ 병목을 해결하기 위해, 노드의 연결 차수(Degree)를 활용한 $O(1)$ 위상적 필터링을 제안했다. [코드 1]은 S-MLFQ의 핵심 강등 및 에이징 로직 코드이다.

```
# [코드 스니펫: 몬테카를로 난수 기반 노이즈 허브 및 함정
# 생성 로직]
for i in range(5):
    hub_name = f"컴퓨터일반-{i}"
    # 1. 노이즈 허브 진입 비용을 의도적으로 낮게 설정 (다
    # 익스트라 유도 함정)
    w_hub = round(random.uniform(0.05, 0.15), 2)
    edges.append({"source": random.choice(golden_path),
                  "target": hub_name, "weight": w_hub})

    # 2. 전체 노드의 30% 비율에 해당하는 무작위 쓰레기 노
    # 드(Noise) 생성 및 허브에 종속
    num_noise = int(100 * NOISE_RATIO) #
    NOISE_RATIO = 0.3
    for j in range(num_noise):
        edges.append({
            "source": hub_name,
            "target": f"노이즈-{i}-{j}",
            "weight": round(random.uniform(0.01, 0.1), 2)
        })
# 내부 탐색 비용 최소화
})
```

[코드 2] 노이즈 허브 및 함정 생성 코드 스니펫

해당 코드는 차수가 비정상적으로 높은 노드를 구조적으로 즉각 차단하고, 특정 주기(Aging Interval)마다 유배된 큐의 지식을 상위 큐로 승격시켜 '통제된 창발성'을 유도하도록 설계되었다.

3.3.4. 벤치마크 데이터셋 동적 생성 로직 및 위상적 설계

알고리즘의 한계를 극한까지 테스트하고 가설을 엄밀하게 증명하기 위해, 고정된 정적 데이터가 아닌 파이썬(auto_benchmark.py)을 활용한 위상 제어형 동적 그래프 생성 파이프라인을 구축하였다. 현실의 '척도 없는 네트워크(Scale-Free Network)' 특성을 반영하되, 각 알고리즘의 기작(Mechanism)을 정확히 타겟팅할 수 있도록 다음 4가지 속성을 지닌 지식 그래프를 동적으로 생성한다.

1) 황금 경로 (Golden Path): 적합성 타겟

인공지능 -> 머신러닝 -> 딥러닝 -> LLM'으로 이어지는 질문의 핵심 문맥이다. 이 경로의 간선 가중치는 매우 낮은 수준(0.1)으로 설정되어, 알고리즘들이 기본적으로 우선 탐색해야 할 정답 궤적을 형성한다.

2) 일반 응용 지식

평가 A의 예산 소진용평가 A(정상 환경)에서 탐색 예산을 자연스럽게 소진하도록 유도하는 노드들이다. 간선 가중치(0.2~0.25)를 황금 경로보다 약간 높게 설정하되, 연결 차수를 1~2개로 제한하여 S-MLFQ가 이를 노이즈 허브로 오인하지 않고 정상 탐색하도록 설계했다.

3) 거대 노이즈 허브 및 극단적 미끼

평가 B 스트레스 환경전체 그래프 크기의 30% 비율에 해당하는 무의미한 노이즈(쓰레기) 노드들을 [코드 2]와 같이 생성한다.

```
// [코드 스니펫: S-MLFQ의 위상적 필터링 및 큐 스케줄링
# 로직]
int next_queue_idx = active_idx;
int next_hop_run = current.current_hop_run + 1;

// 1. 위상적 필터링 (Noise Isolation)
// 차수(Degree)가 임계치(5)를 초과하면 거대 노이즈 허브로
# 간주하고 최하위 큐(Q2)로 강등
if ((*graph_nodes)[next_id].degree > HUB_THRESHOLD)
{
    next_queue_idx = 2;
    next_hop_run = 0;
}

// 2. 피로도 누적 제어 (Context Switching)
// 최상위 큐(Q0)에서 연속으로 2번(HOP_QUANTUM) 탐색
# 시, Q1으로 강등하여 과적합 방지
else if (active_idx == 0 && next_hop_run >=
HOP_QUANTUM) {
    next_queue_idx = 1;
    next_hop_run = 0;
}

// 계산된 우선순위 큐에 다음 탐색 노드 삽입
mlfq[next_queue_idx].push({next_id,
current.cumulative_cost + edge.weight, next_hop_run,
""});
```

[코드 1] S-MLFQ 주요 코드 스니펫

'컴퓨터일반'과 같은 허브 노드로 진입하는 가중치를 극단적으로 낮게(0.001) 설정하여, 눈앞의 진입 비용만 쫓는 다익스트라(SJF)를 1순위로 완벽하게 유인한다. 또한, 위상적 차수를 조작하여, 허브 노드 하나당 30개의 쓰레기 노드(가중치 0.01)를 방사형으로 연결하여 해당 허브의 연결 차수가 31이 되도록 설계했다. 이는 S-MLFQ가 간선 차수(Degree > 5)를 검사하여 $O(1)$ 상수로 노이즈를 처내는 '위상적 필터링' 기능이 정상 작동하는지 검증하기 위한 핵심 장치다.

4) 창발성 타겟 도메인 (Hidden Target)

다양성 타겟인 '뇌과학', 'BCI 기술' 등은 황금 경로와는 멀리 떨어져 있으나 혁신적인 문맥을 제공할 수 있는 이중도메인이다. 이 구역으로 진입하는 간선의 가중치는 극도로 높게(0.9) 설정하여, 비용 최적화 방식으로는 절대 도달할 수 없고 오직 S-MLFQ의 에이징을 통한 문맥 전환 메커니즘으로만 진입할 수 있도록 가혹한 진입 장벽을 두었다.

본 연구의 데이터 제너레이터는 노이즈 주입 비율 파라미터를 통해 두 가지 환경을 동적으로 분리 생성한다. 비율이 0일 때는 함정이 없는 [평가 A] 환경을 구축하며, 비율이 0.3일 때는 아래의 코드 스니펫이 조건부로 발동하여 다익스트라를 유인하는 [평가 B] 전용 적대적 스트레스 환경을 구축한다.

이와 같이 철저히 통제된 위상 설계(Topology Design)를 통해 스트레스 환경을 구축함으로써, 이후 진행될 벤치마크 결과가 어떠한 우연성도 배제된 객관적이고 수학적으로 증명 가능한 실험임을 구조적으로 담보하였다.

3.3.5. 제안 모델(S-MLFQ)의 이론적 시간 및 공간 복잡도 분석

본 연구에서 제안한 S-MLFQ 탐색 엔진은 거대 지식 그래프 환경에서도 실시간(Runtime) 서비스가 가능하도록 고도로 최적화된 자료구조 복잡도를 가진다. (단, 전체 노드의

수를 V , 간선의 수를 E , 탐색 예산을 B 라 정의한다.)

1) 시간 복잡도 : $O(B \log V)$ 및 $O(1)$ 필터링

탐색 및 스케줄링: S-MLFQ는 3개의 우선순위 큐(std::priority_queue)를 운용한다. 매 탐색(Tick)마다 큐에서 최상위 노드를 꺼내고(pop) 주변 노드를 삽입(push)하는 연산은 각각 $O(\log V)$ 의 시간이 소요된다. 전체 탐색은 예산 B 만큼 반복되므로, 기본 탐색 시간 복잡도는 $O(B \log V)$ 이다.

핵심 기여점으로는 위상적 필터링의 $O(1)$ 처리가 있다. 기존의 의미론적 노이즈 필터링은 노드 간의 코사인 유사도를 일일이 계산해야 하므로 심각한 병목을 유발한다. 반면, S-MLFQ는 노드의 연결 차수를 확인하는 연산만으로 거대 노이즈 허브를 판별한다. 이는 메모리 주소 접근만으로 해결되는 $O(1)$ 상수 시간 복잡도를 가지며, 결과적으로 필터링 오버헤드를 수학적으로 완전히 제거한 혁신적인 설계이다.

2) 공간 복잡도 : $O(V)$


S-MLFQ는 탐색 과정에서 발견된 노드들의 상태를 3개의 다중 큐에 나누어 저장하며, 중복 방문을 막기 위해 해시 테이블 기반의 std::unordered_set을 사용한다. 최악의 경우 그래프 내의 모든 유효 노드가 큐나 방문 기록 셋에 적재되더라도, 요구되는 메모리 공간은 노드의 개수 V 에 정비례하므로 $O(V)$ 의 선형 공간 복잡도를 보장한다. 다중 큐를 도입했음에도 추가적인 메모리 팽창(Overhead)이 발생하지 않는 안정적인 구조이다.

4. 실험 및 분석 결과

이 장에서는 앞서 구축한 실험 환경과 데이터를 바탕으로, S-MLFQ 알고리즘의 성능을 3가지 핵심 지표(탐색 효율성, 의미론적 적합성, 다양성) 및 시스템 리소스 관점에서 다각도로 분석한다.

4.1. [평가 A] 통제된 정상 지식망에서의 알고리즘 기본 탐색 성능 분석

본 절에서는 노이즈 허브나 악의적인 함정이 배제된 정상적인 지식 그래프 환경(노이즈 0%)에서 각 알고리즘이 보유한 기본적인 탐색 능력을 평가한다.



[그림 5] 평가 A의 결과 차트

4.1.1. 탐색 효율성 분석

탐색 효율성은 부여된 예산(Budget=40) 내에서 무의미한 중복 방문을 최소화하고 유효한 지식을 얼마나 수집했는지 측정하는 지표다.

1) 다익스트라 (40점): 비용 최적화(SIF) 알고리즘의 특성상, 진입 비용이 저렴하게 설정된 유효 노드(황금 경로 및 일반 응용 지식)들을 순차적으로 방문하며 예산의 낭비 없이 40점 만점을 기록했다.

2) 랜덤 워크 (22점): 무작위 탐색 알고리즘은 가중치를 무시한 채 도약(Teleport)과 인접 노드 방문을 반복한다. 이 과정에서 이미 방문한 노드를 중복해서 맴돌거나, 정보가 없

는 외곽 노드에서 예산을 탕진하여 유효 탐색 수가 22개에 그쳤다.

3) S-MLFQ (40점): 제안 모델 역시 다익스트라와 마찬가지로 40점 만점을 기록했다. 이는 탐색 초기 최상위 큐(Q0)가 유효한 노드들을 정밀하게 락인하여 낭비 없이 탐색 예산을 100% 활용했음을 증명한다.

4.1.2. 의미론적 적합성

분석의미론적 적합성은 사용자의 질문과 가장 직결되는 핵심 문맥인 황금 경로를 얼마나 충실하게 추적했는지 나타낸다.

1) 다익스트라 (12점): 3개 알고리즘 중 가장 높은 적합성을 기록했다. 황금 경로의 간선 가중치가 0.1로 가장 낮게 설정되어 있기 때문에, 오직 눈앞의 최소 비용만을 쫓는 탐욕적 탐색 기법이 정상 환경에서는 가장 완벽하게 정답 궤적을 훑어냄을 보여준다.

2) 랜덤 워크 (4점): 15% 확률의 무작위 도약 메커니즘으로 인해, 정답 경로를 잘 따라가다가도 스스로 궤적을 이탈해버리는 치명적인 의미론적 표류 현상이 발생하여 가장 낮은 점수를 기록했다.

3) S-MLFQ (11점): 다익스트라보다 1점 낮은 최상위권 점수를 기록했다. Q0를 통해 황금 경로를 훌륭하게 추적했으나, 특정 시점에서 에이징이 발동하며 의도적으로 다른 도메인으로 탐색을 전환했기 때문에 다익스트라 수준의 극단적인 과적합에는 도달하지 않았다.

4.1.3. 다양성 및 창발성

분석이 지표는 황금 경로와는 멀리 떨어져 있으나(진입 가중치 0.9), '뇌과학' 등 혁신적인 문맥을 제공할 수 있는 숨겨진 타겟 도메인에 도달한 횟수를 측정한다.

1) 다익스트라 (5점): 순수 비용 최적화의 치명적인 한계인 '국소 최적해(Local Optima)'에 빠진 결과다. 가중치가 0.9인 창발성 도메인의 높은 진입 장벽을 넘지 못하고, 시작점 주변의 저비용 지식만 탐색하다가 예산을 모두 소진했다.


2) 랜덤 워크 (8점): 가중치를 완전히 무시하는 무작위 텔레포트 덕분에 높은 장벽을 넘어 우연히 창발성 도메인에 안착했다. 하지만 이는 논리적 추론의 결과가 아닌 단순 요행이므로 신뢰할 수 있는 성능으로 평가하기 어렵다.

3) S-MLFQ (7점): S-MLFQ가 다익스트라에게 적합성 1점을 내어준 결정적인 이유이자, 본 알고리즘의 핵심 무기가 증명된 결과다. 탐색이 한곳에 정체되면 에이징 메커니즘이 발동하여 노드의 우선순위를 강등(Q0 → Q1)시키고, 이를 통해 의도적인 문맥 전환을 수행하여 창발성 타겟으로 정확히 도약해 내는 데 성공했다.

[평가 A]의 결과를 종합하면, S-MLFQ는 무분별한 텔레포트(랜덤 워크)를 지양하면서도, 다익스트라가 겪는 국소 최적화의 한계를 극복한 모델이다. 즉, 적합성을 1점 양보하는 기회비용을 지불하고 다익스트라가 절대 연지 못하는 창발성을 2점 더 확보함으로써, LLM의 환각을 억제하면서도 풍부한 문맥을 제공하는 최적의 트레이드-오프 밸런스를 입증하였다.

4.2. [평가 B] 적대적 스트레스 환경에서의 필터 버블 방어 능력 검증

본 절에서는 전체 노드의 30%에 해당하는 '거대 노이즈 허브'와 진입 가중치 0.001의 '극단적 미끼'가 주입된 적대적 스트레스 환경에서 각 알고리즘이 악의적인 함정을 어떻게 대처하는지 분석한다.



[그림 3] 평가 B의 결과 차트

4.2.1. 탐색 효율성 분석: 위상적 필터링의 증명

가장 극적인 성능 격차가 발생한 지표로, 비용 최적화 알고리즘의 치명적 약점과 S-MLFQ의 방어 기제가 명확히 대조되었다.

1) 다익스트라 (1점): 탐색을 시작하자마자 가중치가 0.001인 노이즈 허브의 미끼에 완벽하게 유인되었다. 이후 허브 내부에 밀집된 30개의 무의미한 쓰레기 노드(가중치 0.01)들을 탐색하느라 예산 40을 모두 탕진하고 탐색을 조기 종료했다. 이는 알고리즘이 쓰레기 정보의 늪에 빠져 헤어나오지 못하는 전형적인 필터 버블 현상을 수치(1점)로 증명한 것이다.

2) 랜덤 워크 (18점): 가중치를 무시하므로 0.001의 미끼에 맹목적으로 끌려가지는 않았다. 노이즈 밭에 진입하더라도 15%의 텔레포트 확률을 통해 역지로 함정에서 탈출하며 다익스트라보다 높은 18점의 효율성을 기록했다.

3) S-MLFQ (19점): 0.001의 미끼를 마주했을 때, 해당 허브 노드의 연결 차수가 31개(Degree > 5)인 것을 감지하고 즉시 최하위 큐(Q2)로 격리하는 위상적 필터링을 성공적으로 수행했다. 함정을 통째로 도려낸 후 남은 안전한 그래프 공간에서 19개의 유효 노드를 수집하며 가장 높은 탐색 효율을 방어해 냈다.

4.2.2. 의미론적 적합성 분석: 노이즈 우회 능력

극단적인 노이즈의 방해 속에서도 질문의 본질인 '황금 경로'를 얼마나 유지했는지 분석한 결과다.

1) 다익스트라 (0점): 필터 버블에 갇혀 시작점 근처의 쓰레기 노드만 순회했으므로, 정답 궤적인 황금 경로에는 단 한 발자국도 진입하지 못하고 0점을 기록했다. 적대적 환경에서 SJF 기반의 RAG(검색 증강 생성)가 얼마나 치명적인 환각을 유발할 수 있는지 시사하는 대목이다.

2) 랜덤 워크 (3점): 함정은 빠져나왔으나, 잦은 텔레포트와 무작위 이동으로 인해 의미론적 표류를 겪으며 황금 경로를 3개 수집하는 데 그쳤다.

3) S-MLFQ (5점): 3개 알고리즘 중 가장 높은 적합성(5점)을 기록했다. 노이즈 허브를 Q2로 유배시킨 덕분에 귀중한 탐색 예산을 쓰레기 노드에 낭비하지 않고, Q0를 통해 황금 경로를 다시 타겟팅하는 것에 성공했음을 보여준다.

4.2.3. 다양성 및 창발성 분석: 통제된 도약

사방이 노이즈로 둘러싸인 극한의 환경에서, 문맥의 연속성을 유지하면서도 혁신적인 타겟 도메인(가중치 0.9)에 도달할 수 있는지 검증한 결과다.

1) 다익스트라 (0점): 노이즈 허브 내부의 필터 버블 안에서 탐색 예산을 모두 탕진하였으므로, 창발성 타겟 근처에는 도달조차 하지 못했다.

2) 랜덤 워크 (8점): 무작위 텔레포트를 통해 타겟 도메인에 다수 안착하며 표면적으로는 가장 높은 다양성(8점)을 기록했다. 그러나 이는 앞선 4.2.2절의 적합성 점수 폭락(3점)에서 알 수 있듯, 황금 경로와의 논리적 연결을 완전히 상실한 맹목적인 표류의 결과이다. [평가 B]에서 다양성 지표를 통해 궁극적으로 달성하고자 하는 바는 무분별한 텔레포트가 아니라, 기존 문맥을 잃지 않는 선에서 발현되는 '통제된 창발성(Controlled Diversity)'이다. 즉, 제어되지 않은 다양성은 LLM 시스템에서 심각한 환각으로 직결될 뿐, 유의미한 지식의 확장으로 볼 수 없다.

3) S-MLFQ (3점): 노이즈 허브를 잘라내고 남은 좁은 유효 경로 속에서도, S-MLFQ는 에이징 메커니즘을 통해 3개의 창발성 타겟을 수집하는 데 성공했다. 랜덤 워크에 비해 수치는 낮지만, 이는 오히려 S-MLFQ가 문맥적 적합성을 굳건히 방어할 수 있는 선에서만 제한적이고 통제된 도약을 수행했다는 것을 입증한다. 무의미하게 아무 도메인으로 튀는 것이 아니라, 기본 지식과의 논리적 연결 고리를 잃지 않으면서 안전한 형태로 창발성을 발현하는 본 모델의 핵심 철학이 증명된 결과다.

[평가 B]의 결과를 종합하면, 단순 비용 기반 탐색(다익스트라)은 거대 노이즈 환경에서 치명적인 '필터 버블'에 갇혀 완전히 무용지물이 됨을 확인하였다. 또한, 무작위 탐색(랜덤 워크)은 노이즈를 탈출하여 표면적인 다양성을 얻었으나, 이는 문맥을 상실한 '제어되지 않은 텔레포트'에 불과하여 RAG 시스템 적용 시 심각한 환각을 유발할 위험이 큼이 드러났다.


반면 제안 모델인 S-MLFQ는 위상 분석으로 함정을 원천 차단하고(탐색 효율성 방어), 핵심 문맥을 굳건히 유지하면서도(적합성 1위), 에이징 메커니즘을 통해 통제된 창발적 도약을 이뤄내는 데 성공했다. 이는 극한의 적대적 스트레스 환경에서도 LLM의 환각을 억제하는 동시에 안전하고 혁신적인 지식 확장을 이뤄내는 S-MLFQ의 압도적인 위기 대응 능력을 완벽하게 입증하는 결과이다.

4.3. 실측 시스템 리소스 (시간/공간 복잡도) 정밀 분석

본 절에서는 [평가 B](적대적 스트레스 환경) 하에서 C++ 기반 탐색 엔진(smlfq_engine.exe)이 실제로 소모한 순수 실행 시간(ms)과 메모리 공간 점유율(Queue + Log Nodes)을 측정하여, 3.3.5절에서 수립한 복잡도 가설을 교차 검증한다.

4.3.1. 시간 복잡도 및 스케줄링 오버헤드 분석

실측된 실행 시간을 표면적으로 살펴보면 다익스트라(0.0801ms)가 제안 모델인 S-MLFQ(0.0999ms)보다 빠른 연산 속도를 보인 것처럼 관찰된다. 하지만 이는 탐색의 성공 여부를 고려할 때 전혀 다른 컴퓨터 구조론적 해석을 요구한다.



[그림 4] 복잡도 분석 차트

1) 다익스트라의 조기 종료 : 다익스트라는 탐색 시작 직후 가중치가 0.001인 거대 노이즈 허브에 진입하였다. 허브 내부의 좁은 위상 공간 안에서 30개의 쓰레기 노드들만 우선순위 큐에 삽입 및 삭제하며 예산 40을 순식간에 탕진했다. 즉, 연산이 구조적으로 빠른 것이 아니라 필터 버블에 갇혀 '정상적인 궤적 탐색을 포기하고 조기 종료된 결과'로 보아야 한다.

2) 랜덤 워크의 무상태(Stateless) 탐색: 랜덤 워크(0.088 8ms)는 15%의 텔레포트 확률을 통해 노이즈 허브에서 탈출하며 다익스트라보다 오랫동안 생존(유효탐색 18개)했기 때문에 다익스트라보다 긴 실행 시간이 측정되었다. 그러나 무작위 탐색은 노드 간의 가중치를 비교하기 위한 우선순위 정렬($O(\log V)$) 연산이나 복잡한 큐 상태 관리가 필요 없는 단순 난수 기반의 무상태 탐색이므로, 가장 가벼운 연산 부하를 가져 S-MLFQ보다는 빠른 속도를 기록했다.


3) S-MLFQ의 위상적 필터링과 오버헤드: 반면 S-MLFQ는 노이즈 허브를 마주했을 때, 노드의 간선 차수(Degree > 5)를 검사하는 $O(1)$ 상수 시간 연산을 통해 30개의 쓰레기 노드들이 큐에 진입하는 것 자체를 원천 차단(Pruning)했다. 이후 남은 예산을 온전히 소진하기 위해 3개의 다중 큐(Q0, Q1, Q2) 간의 상태를 계산하고 피로도(Hop)를 누적하는 에이징 연산을 끊임없이 수행하며 전체 그래프를 깊게 탐색했다.

S-MLFQ에서 다익스트라 대비 추가로 발생한 약 0.019ms의 시간차는 비효율이 아니라, 3개의 큐를 동시에 관리하고 유효한 문맥 전환을 계산하기 위해 지불한 '필수적인 스케줄링 오버헤드'이다. 노이즈 처리에 소모되는 $O(\log V)$ 병목을 $O(1)$ 로 차단했기 때문에, 이 정도의 미세한 오버헤드만으로도 압도적인 탐색 성능과 생존력(효율성 19점)을 성공적으로 방어해 낼 수 있었던 것이다.

4.4. 실제 지식망에서의 탐색 궤적 정성 평가

본 절에서는 앞서 확인한 정량적 수치(효율성, 적합성, 다양성)와 실측 복잡도 데이터가 실제 지식망 위에서 어떠한 위상적 궤적으로 발현되는지 시각적으로 증명한다.

거대 노이즈 허브(30%)가 주입된 [평가 B]의 지식망 토폴로지를 회색 점선으로 펼친 뒤, C++ 엔진이 뿔어낸 실제 메모리 방문 순서를 굵은 실선 화살표로 레이어링 하였다. (단, 궤적의 엉킴 현상을 방지하고 노이즈 허브 대면 시 알고리즘들의 초기 의사결정 메커니즘을 명확히 관찰하기 위해, 시각화 렌더링에 한하여 탐색 예산을 초반 15단계로 통제하였다.)



[그림 51] 실제 탐색 궤적 그래프

4.4.1. 대조군의 한계: 다익스트라의 국소 최적화 및 랜덤 워크의 표류 현상

1) 다익스트라(Baseline)의 궤적 (좌측 패널): 시각화 결과, 다익스트라의 굵은 탐색 궤적은 시작 직후 가중치가 0.001로 설정된 회색 노드(거대 노이즈 허브) 군집으로 강하게 빨려 들어가는 것이 명확히 관찰된다. 이후 궤적은 외부로 뻗어나가지 못하고 회색 쓰레기 노드들 사이에서만 어지럽게 엉켜있다(Local Optima). 이는 앞서 4.2.1절에서 분석한 필터 버블에 갇혀 예산을 탕진하고 조기 종료되는 현상을 완벽하게 시각적으로 증명한다.

2) 랜덤 워크의 궤적 (중앙 패널): 무작위 탐색의 궤적은 노란색(황금 경로)과 붉은색(창발성 타겟) 노드들을 넘나들고 있으나, 선형적인 논리 구조 없이 그래프 전역을 산발적이고 난잡하게 가로지르고 있다. 목적성이 결여된 도약으로 인해 문맥의 연속성이 파괴되는 전형적인 의미론적 표류 현상이다.

4.4.2. 제안 모델(S-MLFQ)의 위상적 감지 및 통제된 회귀 메커니즘 입증

S-MLFQ의 궤적 (우측 패널): 제안 모델의 궤적은 대조군들과는 완전히 다른 우아한 선형적 방향성과 통제력을 보여준다. 가장 주목할 점은 궤적의 순서다. 탐색 초기, 궤적이 2개의 회색 노드(노이즈 허브)와 접촉하였으나, 다익스트라처럼 그 내부로 깊숙이 빨려 들어가지 않고 즉각적으로 궤적을 끊어 이탈(Escape)하는 모습이 관찰된다. 이는 S-MLFQ가 노이즈 노드를 마주치더라도 연결 차수(Degree)를 확인하여 $O(1)$ 상수 시간 내에 최하위 큐(Q2)로 격리해 버리는 '위상적 필터링(Topological Filtering)'이 완벽하게 작동했음을 증명한다. 더욱 혁신적인 것은 노이즈를 탈출한 직후의 행동이다. 궤적은 회색 노드를 벗어나자마자 곧바로 붉은색 노드(창발성 도메인)로 과감한 도약을 수행한다. 노이즈 주변의 함정을 피하기 위해 에이징 메커니즘을 발동시켜 고가중치 장벽을 넘는 문맥 전환을 이뤄낸 것이다. 이후 창발적 지식을 확보한 궤적은 멈추지 않고 다시 노란색 군집(기본 황금 경로)으로 진입하여 촘촘하게 안착한다. 이는 시스템이 궤적을 잃고 표류(랜덤 워크)하는 것이 아니라, 새로운 지식을 탐색(Red)한 후에도 질문의 본질적 적합성(Yellow)을 지키기 위해 안전하게 회귀하는 통제된 창발성의 완벽한 시각적 증거이다.

4.5. 실험 및 분석 결과 총평

정량적 벤치마크, 시스템 복잡도 실측, 그리고 정성적 궤적 시각화를 모두 종합한 결과, S-MLFQ는 단순한 비용 최적화(SJF) 알고리즘이 지닌 치명적인 필터 버블과 환각의 위험성을 극복해 냈다. 노이즈를 위상적으로 차단하고, 의미론적으로 유효한 지식을 취사선택하며, 창발적인 문맥까지 확장하는 본 모델은 차세대 거대 지식 그래프 탐색을 위한 가장 견고하고 효율적인 구조임이 다각도로 증명되었다.

5. 결론 및 향후 연구 방향

5.1. 연구 요약 및 학술적 의의

본 연구는 거대 언어 모델(LLM)이 지식 그래프를 탐색할 때 발생하는 메모리 병목 현상과, 문맥 상실로 인한 환각 문제를 근본적으로 해결하기 위해 'S-MLFQ (Semantic Multi-Level Feedback Queue)' 탐색 알고리즘을 제안하고 그 효용성을 다각도로 입증하였다. 기존의 단순 비용 최적화(SJF) 알고리즘인 다익스트라는 적대적 노이즈 환경에서 치명적인 필터 버블에 갇혀 완전히 무력화되었으며, 무작위 탐색은 문맥을 상실한 채 표류하는 한계를 보였다. 반면, 제안 모델인 S-MLFQ는 다음 두 가지 핵심 학술적 기여를 통해 이 한계를 돌파하였다.

1) $O(1)$ 위상적 필터링 : 노드의 연결 차수만을 검사하여 거대 노이즈 허브를 판별함으로써, 연산 부하 없이 악의적인 함정을 즉각적으로 차단하는 방어 기제를 수학적으로 증명하였다.

2) 통제된 창발성 : 다중 큐의 에이징 메커니즘을 통해 황금 경로(정답)에 대한 의미론적 적합성을 굳건히 유지하면서도, 혁신적인 타겟 도메인으로 징검다리 도약(Leap)을 수행하는 최적의 트레이드-오프 밸런스를 달성하였다.

결과적으로 S-MLFQ는 단순한 검색 알고리즘을 넘어, LLM이 '안전하면서도 창의적으로' 지식을 확장할 수 있도록 돕는 차세대 스케줄링 아키텍처로서의 학술적 의미를 지닌다.

5.2. 실무적/산업적 기대 효과

본 연구의 결과물은 단순한 이론적 검증을 넘어 실제 산업 현장에 즉시 적용될 수 있는 강력한 실무적 이점을 제공한다.

1) 기업용 신뢰성 RAG 구축 및 XAI(설명 가능한 인공지능)로의 확장: 기존의 딥러닝 기반 탐색이나 벡터 유사도 검색은 결과 도출 과정을 알 수 없는 블랙박스의 한계가 있었다. 반면 S-MLFQ는 "[수집] Q0 안착 -> [필터링] Q2 격리 -> [도약] Q1 에이징"으로 이어지는 모든 의사결정 과정이 뚜렷한 자료구조 상태 로그로 남는다. 이는 기업형 AI 시스템에서 답변의 근거를 추적하고 환각의 원인을 디버깅(Auditing)할 수 있는 완벽한 XAI 파이프라인으로 활용될 수 있다.

2) 차세대 Graph RAG 파이프라인의 핵심 엔진: [Track 1]의 웹 기반 실시간 탐색 서비스 데모를 통해 입증하였듯, 사용자의 비정형 자연어 입력부터 LLM 기반 지식 추출, 그리고 S-MLFQ를 통한 동적 렌더링 및 XAI 로그 출력까지 이어지는 End-to-End 파이프라인이 상용화 수준으로 성공적으로 구현되었다.

3) 엣지 컴퓨팅 및 온디바이스 AI 최적화: 4.3절의 복잡도 실측 결과에서 확인되었듯, S-MLFQ는 전체 노드 수(V)에 비례하는 O(V)의 안정적인 선형 공간 복잡도를 유지한다. 이는 극도로 제한된 메모리 환경(스마트폰, IoT 기기 등)에서도 거대 지식망의 로컬 탐색을 가능하게 하여 온디바이스 RAG 기술의 발전에 크게 기여할 수 있다.

5.3. 본 연구의 한계점

본 연구가 제안하는 S-MLFQ 아키텍처는 스트레스 환경에서 탁월한 방어력을 보여주었으나, 실제 상용화 및 범용적 적용을 위해서는 다음과 같은 몇 가지 한계점을 내포하고 있다.

1) 하이퍼파라미터 설정의 민감도: S-MLFQ의 탐색 성능은 다중 큐 간의 에이징 임계치, 위상적 필터링을 판단하는 차수의 기준값, 그리고 전체 탐색 예산의 설정값에 따라 그 결과(적합성과 창발성의 비율)가 매우 민감하게 변화한다. 즉, 탐색하려는 지식 그래프의 도메인 특성(의학, 법률, 일반 상식 등)에 따라 관리자가 파라미터를 수동으로 정밀하게 조율(Tuning)해야만 최적의 성능을 낼 수 있다는 구조적 의존성이 존재한다.

2) 위상적 필터링의 정적 임계치 한계: 본 연구의 [평가 B]에서 설정한 노이즈 차수 임계치($k > 5$)는 제안 모델의 O(1) 필터링 메커니즘이 극한의 함정 속에서 작동하는지를 개념 증명하기 위해 통제된 하이퍼파라미터다. 실제 범용적인 지식 그래프에서는 '인공지능'이나 '머신러닝' 같은 핵심 도메인 노드 역시 필연적으로 높은 연결 차수를 가진다(Scale-Free Network의 허브 특성). 따라서 현재의 정적 임계치 방식은 핵심 개념을 노이즈로 오판할 위험을 내포하고 있으며, 이를 실제 데이터셋에 적용하기 위해서는 단순 차수 비교가 아닌 가중치 대비 차수 비율 등을 활용한 동적 임계치 알고리즘으로의 고도화가 필수적이다.

5.4. 향후 발전 방향

위에서 논의된 한계점을 극복하고 S-MLFQ를 더욱 완전한 형태의 탐색 지능으로 발전시키기 위해, 향후 다음과 같은 후속 연구를 제안한다.

1) RL 기반 적응형 S-MLFQ : 알고리즘의 파라미터 민감도를 해결하기 위해, 에이전트가 지식망의 밀도와 위상을 실시간으로 학습하고 평가하는 강화학습(RL) 모델의 도입이 필요하다. 인공지능이 도메인의 특성을 스스로 파악하여 에이징 임계치와 예산을 동적으로 자동 튜닝하는 '적응형 S-MLFQ'로의 발전이 요구된다.

2) 동적 가중치 모델링 및 벡터 결합: 사용자의 후속 질의에 따라 그래프 내의 가중치가 실시간으로 업데이트되는 동적 환경을 구축할 수 있다. 나아가 기존의 텍스트 기반 지식 그래프를 넘어, 임베딩 벡터 데이터베이스(Vector DB)와의 네이티브 결합을 통해 멀티모달 데이터까지 탐색할 수 있는 통합 지식 스케줄링 아키텍처로 확장 가능하다.

6. LLM 활용 기록

본 장에서는 프로젝트의 기획, 코어 엔진 개발, 그리고 웹 파이프라인(Track 1) 구축 전반에 걸쳐 대형 언어 모델(LLM)을 어떻게 활용했는지 구체적으로 기록하고, 그 결과물에 대한 비판적 고찰을 서술한다.

6.1. LLM 활용 파이프라인 개요

본 프로젝트에서는 목적에 따라 두 가지 다른 LLM 환경을 분리하여 활용하였다.

1) 개발/연구 보조 : Gemini Advanced (클라우드 환경): C++ 기반 S-MLFQ 엔진의 복잡도(Time/Space Complexity) 최적화 아이디어 도출, 파이썬 기반 데이터 제너레이터(Topology Design) 스크립트 작성 보조, 그리고 논문의 학술적 논리 구조(Trade-off 분석 등)를 교차 검증하는 페어 프로그래머(Pair Programmer) 및 리뷰어로 활용하였다.

2) 시스템 내부 컴포넌트 : Llama 3.1 (로컬 Ollama 환경): Track 1 웹 서비스의 백엔드(app.py)에서 사용자의 비정형 자연어를 입력받아 엔티티와 관계를 추출해 내는 지식 추출 엔진 컴포넌트로 시스템 내부에 직접 탑재하여 활용하였다.

6.2. 프롬프트 엔지니어링 적용 사례

LLM의 환각을 줄이고 원하는 형태의 결과물을 얻기 위해 구체적인 제약 조건을 부여하는 프롬프트 엔지니어링을 수행하였다.

6.2.1. 사례 1: Track 1의 지식 그래프 강제 연결성 부여

초기 로컬 LLM(Llama 3.1)은 텍스트를 분석할 때, 단어 간의 관계를 파편화된 형태(단절된 노드들)로 뱉어내는 문제가 있었다. 이를 해결하기 위해, 프롬프트 내부에 "이전 문장의 핵심 개념과 현재 문장의 핵심 개념 사이에 2개 이상의 'context_flow' 엣지를 생성하였고, 전체 그래프가 하나의 거대한 연결 그래프(Connected Graph)가 되도록 하십시오"라는 형식으로 여러개의 위상적 제약 조건(CRITICAL RULES)을 시스템 프롬프트로 강제 주입하여 문제를 해결하였다.

```
def extract_knowledge(text):
    print(f"🔍 [ollama] 로컬 AI 모델 분석 시작...")
    url = "http://127.0.0.1:11434/api/generate"

    prompt = """
    You are a Knowledge Graph extraction expert. Analyze the given text and extract entities (nodes) and their relations (edges).


    CRITICAL RULES:
    1. Respond ONLY with a valid JSON object matching the schema below. No conversational text, no explanations.
    2. Match the language of the 'relation', 'source', and 'target' to the input text.
    3. Extract as many relations as possible (at least 3-5 edges).
    4. 반드시 문장 간 연결성을 고려하십시오. 이전 문장의 주요 개념을 다음 문장의 개념과 'context_flow' 관계로 연결하십시오.
    5. 매우 중요: 이전 문장의 핵심 개념과 현재 문장의 핵심 개념 사이에 2개 이상의 'context_flow' 엣지를 생성하여, 전체 그래프가 하나의 거대한 연결 그래프(Connected Graph)가 되도록 하십시오.
    """
```

[그림 6] 사례 1

6.2.2. 사례 2: 적대적 스트레스 환경(평가 B) 생성기 설계

평가 B의 데이터셋을 생성하기 위해 초기에는 LLM에게 "30%의 노이즈가 섞인 랜덤 지식 그래프를 생성하는 파이썬 코드를 작성해 줘"라고 단순히 요청했다. 그러나 LLM은 그래프 전역에 노이즈를 균일하게 흩뿌리는 코드를 생성했고, 이는 다익스트라의 탐욕적 탐색을 완벽하게 함정에 빠뜨리기에는 위상적으로 부족했다.

따라서, 다익스트라나 랜덤워크를 확실하게 유인하기 위해서는 '균일한 노이즈'가 아니라 '특정 허브로의 집중'이 필요하다고 판단했다. 따라서 LLM에게 다익스트라의 약점을 설명하며 프롬프트를 다음과 같이 구체화하여 재요청했다.



[그림 7] 사례 2의 대화창


그 결과, 개발자의 의도대로 위상적 제약이 완벽하게 통제된 파이썬 생성기(auto_benchmark.py) 코드로 수정해 내었으며, LLM을 단순한 코드 생성기가 아닌 '의도를 수학적으로 구현해 주는 페어 프로그래머'로 성공적으로 활용했다.

6.2.3. 사례 3: 시각화 시뮬레이션에서의 데이터 환각 검증 및 극복

S-MLFQ 코어 엔진의 탐색 궤적을 3단 네트워크 그래프로 시각화하기 위해 LLM에게 파이썬 시각화 코드 작성을 요청했다. LLM은 즉각적으로 훌륭한 디자인의 시각화 코드를 생성했으나, 코드를 상세히 리뷰한 결과 치명적인 문제가 발견되었다. LLM이 생성한 코드는 실제 C++ 엔진이 연산한 메모리 방문 로그를 연동한 것이 아니라, 단순히 알고리즘의 '이론적 예상 궤적'을 하드코딩하여 임의로 그래프를 그려내는 형태였다.

이는 실제 엔진의 실행 결과를 반영하지 않은 시각화는 연구의 실증적 타당성을 완전히 훼손하는 심각한 오류다. LLM이 복잡한 프로세스 간 통신(IPC)이나 로그 파싱 로직을 구현하는 대신, 결과를 그럴싸하게 꾸며내는 지름길을 택했음을 간파했다.

따라서, 가짜 데이터를 생성하는 로직을 코드에서 전면 삭제하고, LLM에게 다음과 같은 명확한 구조적 제약을 주입했다. 그 결과, LLM의 환각을 통제하고 실제 코어 엔진의 실측 데이터에 기반한 100% 정직한 학술적 시각화 파이프라인을 구축하는 데 성공했다.



[그림 8] 사례 3의 대화창

이를 통해 LLM 생성 코드에 대한 맹목적 신뢰의 위험성을 확인하고, 개발자의 철저한 검증 역량이 필수적임을 입증하였다.

[참고문헌]

- [1] D. Edge, H. Trinh, N. Cheng, B. Bradley, A. Chao, A. Mody, S. Truitt, and J. Larson, "From Local to Global: A Graph RAG Approach to Query-Focused Summarization," arXiv preprint arXiv:2404.16130, 2024.
- [2] E. W. Dijkstra, "A note on two problems in connexion with graphs," Numerische Mathematik, vol. 1, pp. 269-271, 1959.
- [3] R. Angles and C. Gutierrez, "Survey of graph database models," ACM Computing Surveys (CSUR), vol. 40, no. 1, pp. 1-39, 2008.
- [4] L. Page, S. Brin, R. Motwani, and T. Winograd, "The PageRank citation ranking: Bringing order to the Web," Stanford InfoLab, Tech. Rep., 1999.
- [5] A.-L. Barabási and R. Albert, "Emergence of scaling in random networks," Science, vol. 286, no. 5439, pp. 509-512, 1999.
- [6] A. Silberschatz, P. B. Galvin, and G. Gagne, Operating System Concepts, 10th ed. Wiley, 2018.
- [7] Meta AI, "The Llama 3 Herd of Models," arXiv preprint arXiv:2407.21783, 2024.
- [8] A. A. Hagberg, D. A. Schult, and P. J. Swart, "Exploring network structure, dynamics, and function using NetworkX," in Proceedings of the 7th Python in Science Conference, pp. 11-15, 2008.